

研究生人工智能入门 Bootstrap 指南（4 周）

适用对象：人工智能基础较薄弱、目前主要会使用 ChatGPT / Claude / Codex 等 AI 工具完成概念性任务的研究生

学习周期：4 周

建议投入：每周 18–22 小时

目标：一个月后能够看懂主流 AI 项目的基本结构，理解当前人工智能技术地图，独立运行和修改基础模型代码，并能开始阅读 AI 前沿论文。

0. 一个月后的目标

一个月后，你至少应该能够：

- 解释人工智能、机器学习、深度学习、生成式 AI 的关系。
- 解释神经网络如何通过 loss、gradient 和 optimizer 学习。
- 说明 CNN、Transformer、LLM 的核心思想。
- 理解 token、embedding、attention、pretraining、fine-tuning、post-training、inference。
- 理解 RAG、tool calling、AI Agent、memory、planning、verifier、evaluation。
- 独立运行并修改一个 PyTorch 项目。
- 使用 Git/GitHub 管理科研代码。
- 借助 AI 写代码，但能解释自己项目中的核心模块。
- 在 30–60 分钟内初步读懂一篇 AI 论文的 problem、method、data、evaluation 和 limitation。
- 对当前 AI 前沿有一张基本技术地图。

这个月结束时，你需要建立的是一张足够清楚的“AI 地图”。

1. 学习规则

1.1 可以大量使用 AI 辅助学习和写代码

鼓励使用 ChatGPT、Claude、Codex、Gemini、GitHub Copilot 等工具。

但是必须遵守：

AI 可以替你生成代码，但不能替你理解代码。

导师可能随机抽你项目中的 20–30 行核心代码，让你解释：

- 输入是什么？
- 输出是什么？
- 张量 shape 是什么？
- 为什么这样写？
- 删除这一段会发生什么？
- 这一步是在训练还是推理？

解释不了就不算掌握。

1.2 不追求“看完课程”，追求“跑通东西”

这四周不要只看，要动手。尽量做到：

- 跑通 2~3 个 notebook 或小项目；
- 提交 3~5 次 GitHub commit；

禁止只汇报：“我看了 10 个小时视频。”

应该汇报：“我跑了这个实验，修改了这个参数，结果从 X 变成 Y，我现在不理解的是 Z。”

1.3 数学按需补

遇到需要的概念再补：


- 向量 / 矩阵
- 导数 / 梯度
- 概率
- softmax
- cross entropy
- expectation

第一阶段只要求理解它们在模型里“起什么作用”。

2. 一个月技术地图

Artificial Intelligence

↓



你这个月的任务，就是把这张图里的每一个关键词从“听说过”变成“知道它大概是什么”。

3. Week 1：机器学习与深度学习基础

本周目标

本周学前自测：

1. 什么是 supervised learning?
2. train / validation / test 有什么区别?
3. 什么是 overfitting?
4. 神经网络如何通过 loss 和 gradient 学习?
5. PyTorch 的 Dataset、DataLoader、Model、Loss、Optimizer 分别在做什么?
6. CNN 为什么适合处理图像?

主课程（如果有的知识已经理解了，可以自行选择内容跳看）

1. 李宏毅老师《生成式人工智能与机器学习导论》

官方课程页：

<https://speech.ee.ntu.edu.tw/~hylee/GenAI-ML/2025-fall.php>

李宏毅老师官方 YouTube：

<https://www.youtube.com/@HungyiLeeNTU>

建议优先看：

- Machine Learning / Deep Learning 基础
- Neural Network Training
- Optimization
- CNN

老版课程补充：

<https://speech.ee.ntu.edu.tw/~hylee/ml/2021-spring.php>

2. Stanford CS231n

<https://cs231n.stanford.edu/>

重点理解：

- convolution
- kernel / filter
- feature map
- pooling
- receptive field
- ResNet
- ImageNet

不要求手推复杂公式。

使用 MNIST 或 FashionMNIST 训练一个简单神经网络。

代码中必须出现并理解：

```
Dataset  
DataLoader
```

```
Model
forward()
loss
loss.backward()
optimizer.step()
evaluation
```

必须理解：

```
Input
↓
Model
↓
Prediction
↓
Loss
↓
Backward
↓
Gradient
↓
Optimizer
↓
Updated Model
```

必须记录 training loss、validation accuracy、learning rate、epoch、batch size。

做两个小实验，例如：

1. learning rate 改 10 倍会发生什么？
2. 隐藏层大小改变会发生什么？

Week 1 小项目

做一个图像分类 baseline：

```
Dataset
↓
DataLoader
↓
CNN / ResNet18
↓
```

```
Training
↓
Evaluation
```

推荐 CIFAR-10 或 FashionMNIST。

GitHub:

```
week1/image_classification/
```

README 写清楚:

- 任务
- 数据
- 模型
- 运行方法
- 最终结果
- 两个对照实验
- 学到了什么

Week 1 验收

必须能回答:

1. 为什么需要 loss?
2. `loss.backward()` 做了什么?
3. `optimizer` 做了什么?
4. `train` 和 `test` 有什么区别?
5. 为什么测试集不能用来调参数?
6. CNN 为什么适合图像?
7. 什么是过拟合?

4. Week 2: Transformer、Foundation Model 和 LLM

本周目标

理解:

- token
- embedding

- attention
- self-attention
- Transformer
- pretraining
- fine-tuning
- instruction tuning
- post-training
- context window
- inference

主课程（如果有的知识已经理解了，可以自行选择内容跳看）

1. 李宏毅 Machine Learning 2021：

<https://speech.ee.ntu.edu.tw/~hylee/ml/2021-spring.php>

重点看 Self-Attention、Transformer。

画出：

```
Token
↓
Embedding
↓
Self-Attention
↓
Feed Forward
↓
Transformer Block
↓
Next Token Prediction
```

必须能回答：

Attention 为什么可以让一个 token 使用其他 token 的信息？
LLM 是怎么来的？

重点理解：

```
大量文本
↓
Pretraining
↓
```

```
Base Model
  ↓
Instruction / Post-training
  ↓
Assistant Model
  ↓
Inference
```

知道：

- next-token prediction
 - autoregressive generation
 - temperature
 - context
 - hallucination
-

使用 Hugging Face

官方：

<https://huggingface.co/>

Transformers：

<https://github.com/huggingface/transformers>

课程：

<https://huggingface.co/learn>

完成至少一个任务：

- sentiment classification
- text generation
- embedding
- zero-shot classification

重点理解：

```
Tokenizer
  ↓
Model
  ↓
```

```
Tensor
↓
Output
```

Embedding 和语义搜索

准备 30–100 段文本，做一个最小语义搜索系统：

```
Documents
↓
Embedding Model
↓
Vectors
↓
Query Embedding
↓
Similarity
↓
Top-k Documents
```

理解为什么 embedding 可以用于搜索、聚类、推荐、RAG。

做一个最小 RAG

实现：

```
User Question
↓
Embedding
↓
Retrieve Documents
↓
Context + Question
↓
LLM
↓
Answer
```

必须回答：

1. RAG 和 fine-tuning 有什么区别？
2. 为什么 RAG 能减少部分 hallucination？
3. retrieval 错了会发生什么？

Week 2 交付物

```
week2/  
├─ huggingface_demo/  
├─ semantic_search/  
└─ simple_rag/
```

写 week2_summary.md , 最多 2 页, 回答:

| 一个现代 LLM 系统从 token 到最终回答, 中间发生了什么?

5. Week 3: AI Agent 入门

本周目标

理解:

| Agent 不是“更大的 LLM”。

一个 Agent 通常是:

```
Model  
+ Context  
+ Memory  
+ Tools  
+ Environment  
+ Control Logic  
+ Evaluation
```

Agent 是什么?

李宏毅 Agent / Context Engineering:

<https://speech.ee.ntu.edu.tw/~hylee/GenAI-ML/2025-fall.php>

Anthropic — Building Effective Agents:

<https://www.anthropic.com/engineering/building-effective-agents>

Lilian Weng — LLM Powered Autonomous Agents:

<https://lilianweng.github.io/posts/2023-06-23-agent/>

Berkeley AI Research — Compound AI Systems:

<https://bair.berkeley.edu/blog/2024/02/18/compound-ai-systems/>

Stanford CS329A Self-Improving AI Agents

<https://cs329a.stanford.edu>

Hugging Face Agents Course

官方:

<https://huggingface.co/learn/agents-course/en/unit1/introduction>

重点:

- Thought
 - Action
 - Observation
 - Tools
 - Agent loop
 - Evaluation
-

阅读一个真正的 Agent 项目

推荐:

mini-SWE-agent

<https://github.com/SWE-agent/mini-swe-agent>

smolagents

<https://github.com/huggingface/smolagents>

要求 clone 其中一个，只回答:

1. agent loop 在哪里?
2. model 在哪里调用?

3. tool / environment 在哪里？
4. history 怎么保存？
5. 什么情况下 agent 停止？

Agent Evaluation

建立 30–50 个固定任务。

每次记录：

```
task
success / failure
answer
tool calls
trajectory
latency
token usage
failure reason
```

计算：

```
success_rate
average_tool_calls
average_latency
average_tokens
```

理解：

没有 evaluation，就无法判断一个 Agent 是否真的更好。

Week 3 项目

实现一个可以调用至少两个工具的 AI Agent，并包含：

```
Agent
Tools
Task Set
Evaluator
Logs
README
```

GitHub:

```
week3/simple_agent/
```

6. Week 4: AI 前沿地图 + 综合项目 + 论文阅读

理解当前 AI 的研究地图

至少知道下面这些方向在做什么。

Foundation Model

- larger-scale pretraining
- multimodal models
- domain foundation models

Post-training

- supervised fine-tuning
- preference learning
- reinforcement learning
- verifiers

Reasoning

- chain-of-thought
- search
- test-time compute
- self-consistency
- verifier-guided reasoning

Agent

- tool use
- planning
- memory
- computer use
- coding agent
- web agent

Agent Evaluation

- long-horizon tasks
- benchmark
- judge
- environment
- reliability

Self-Improving AI

- reflection
- memory
- experience
- trajectory learning
- prompt/program optimization
- automated agent design
- continual learning
- RL

Multimodal AI

- text
 - image
 - audio
 - video
 - scientific data
 - medical data
-

Agent Engineering

Stanford CS329Z:

<https://cs329z.stanford.edu/>

重点浏览:

- compound AI systems
- context engineering
- RAG

- tool calling
 - MCP
 - agent orchestration
 - memory
 - evaluation
 - prompt/program optimization
-

Day 19: 综合项目

三个人都做同一种性质的项目：

构建一个可评测的 AI 系统。

简单 Coding Agent

```
task
↓
generate code
↓
run test
↓
observe error
↓
modify code
↓
rerun
```

必须做 Baseline，例如：

```
Baseline:
single LLM call

System:
RAG / Tool / Agent
```

比较：

- success rate
- accuracy
- latency

- token usage
 - failure cases
-

Day 20: 最终整理

推荐仓库结构：

```
ai-bootstrap-yourname/  
|  
├─ README.md  
├─ requirements.txt  
├─ week1/  
│   └─ image_classification/  
├─ week2/  
│   ├── huggingface_demo/  
│   ├── semantic_search/  
│   └─ simple_rag/  
├─ week3/  
│   └─ simple_agent/  
├─ week4/  
│   └─ final_project/  
├─ papers/  
│   └─ paper_notes.md  
└─ notes/  
    ├── week1_summary.md  
    ├── week2_summary.md  
    ├── week3_summary.md  
    └─ final_reflection.md
```

7. 一个月必须完成的 15 篇论文阅读

每篇只需要回答：

1. Problem
2. Why important?
3. Key idea
4. Method
5. Dataset / Environment
6. Evaluation
7. Main result

- 8. Limitation
- 9. One question

建议：

- InstructGPT
- ReAct
- 一篇 tool-using / coding agent / web agent 论文
- 一篇与未来研究方向相关的论文

8. 推荐课程与资源

机器学习 / 深度学习

李宏毅《生成式人工智能与机器学习导论》

<https://speech.ee.ntu.edu.tw/~hylee/GenAI-ML/2025-fall.php>

李宏毅官方 YouTube

<https://www.youtube.com/@HungyiLeeNTU>

李宏毅 Machine Learning 2021

<https://speech.ee.ntu.edu.tw/~hylee/ml/2021-spring.php>

MIT 6.S191

<https://introtodeeplearning.com/>

MIT 6.S191 GitHub

<https://github.com/MITDeepLearning/introtodeeplearning>

Stanford CS231n

<https://cs231n.stanford.edu/>

PyTorch / Hugging Face

PyTorch Basics

<https://docs.pytorch.org/tutorials/beginner/basics/>

Hugging Face

<https://huggingface.co/>

Transformers

<https://github.com/huggingface/transformers>

Hugging Face Learn

<https://huggingface.co/learn>

Agent

Hugging Face Agents Course

<https://huggingface.co/learn/agents-course/en/unit1/introduction>

Stanford CS329A

<https://cs329a.stanford.edu/>

Stanford CS329Z

<https://cs329z.stanford.edu/>

mini-SWE-agent

<https://github.com/SWE-agent/mini-swe-agent>

smolagents

<https://github.com/huggingface/smolagents>

DSPy

<https://github.com/stanfordnlp/dspy>

推荐博客

Anthropic — Building Effective Agents

<https://www.anthropic.com/engineering/building-effective-agents>

Berkeley AI Research — Compound AI Systems

<https://bair.berkeley.edu/blog/2024/02/18/compound-ai-systems/>

Lilian Weng — LLM Powered Autonomous Agents

<https://lilianweng.github.io/posts/2023-06-23-agent/>

10. 月底最终交付物

10.2 一个 15 分钟报告

题目：

一个月后，我理解的现代人工智能技术地图

必须讲清楚：

Machine Learning
↓
Deep Learning
↓
CNN / Transformer
↓
Foundation Model
↓
LLM
↓
RAG / Tools
↓
Agent
↓
Memory / Planning / Evaluation
↓
Self-Improving AI

10.3 五篇论文阅读记录

统一模板：

Problem:
Key Idea:
Method:
Data:
Evaluation:
Result:
Limitation:
My Question:

10.4 一页 Research Proposal

写：

- 我想研究什么？
 - 为什么重要？
 - 现在别人怎么做？
 - 我想尝试什么？
 - 怎么知道做得好不好？
-

11. 月底口试问题

基础

1. 机器学习和深度学习有什么区别？
2. 什么是 train / validation / test？
3. 为什么会过拟合？
4. loss 和 metric 有什么区别？
5. gradient descent 是什么？

Deep Learning

6. CNN 为什么适合图像？
7. Transformer 为什么重要？
8. attention 在做什么？
9. embedding 是什么？

LLM

10. LLM 为什么叫 next-token prediction？
11. pretraining 和 fine-tuning 有什么区别？
12. 什么是 post-training？
13. temperature 是什么？
14. hallucination 为什么出现？

RAG

15. RAG 是什么？
16. embedding retrieval 怎么工作？
17. RAG 和 fine-tuning 有什么区别？

Agent

18. Agent 和普通 chatbot 有什么区别？
19. tool calling 是什么？
20. memory 有什么用？
21. planning 有什么用？
22. 为什么 Agent 需要 evaluation？

Research

- 23. 为什么“能跑 GitHub”不等于做研究？
 - 24. baseline 为什么重要？
 - 25. ablation 是什么？
 - 26. benchmark 有什么问题？
 - 27. 如何判断一个系统是真的变强，而不是只对 demo 更好？
-

12. 什么叫“通过这个 Bootstrap”？

合格

能够：

- 自己维护 GitHub repo；
- 独立运行 PyTorch 项目；
- 修改模型或超参数并解释结果；
- 使用 Hugging Face 模型；
- 实现简单 RAG；
- 实现简单 tool-using agent；
- 建立基本 evaluation；
- 阅读 AI 论文并做结构化总结；
- 讲清现代 AI 的技术地图。

不合格的典型表现

情况 1

“代码都是 AI 写的，我不知道里面具体是什么意思。”

不合格。

情况 2

“Agent 跑起来感觉挺聪明。”

但没有固定任务集和 evaluation。

不合格。

情况 3

“我看了很多视频。”

但 GitHub 没有代码。

不合格。

情况 4


“这个论文效果很好。”

但说不清 baseline、dataset、metric、limitation。

不合格。

13. 一个月之后怎么办？

完成这个 Bootstrap 后，再开始分方向：



第一个月不要急着追求“创新”。

最重要的是：

建立共同语言、共同技术底座和共同研究方法。

之后再进入各自研究方向，会快很多。

最后一条要求

这个月最重要的不是记住多少模型名字，而是形成以下习惯：

遇到一个 AI 系统，先问：输入是什么？模型是什么？数据是什么？训练信号是什么？输出是什么？怎么评价？baseline 是什么？失败在哪里？

如果你能持续这样思考，你就已经开始从“AI 使用者”向“AI 研究者”转变。